



INFORME EJECUTIVO

Camila Daniela Zapata Castañeda

Descripción de la estrategia

La estrategia de trading implementada se basa en la confluencia de señales provenientes de tres indicadores técnicos complementarios: la Media Móvil Exponencial (EMA), el indicador de Convergencia/Divergencia de Medias Móviles (MACD) y el Índice Direccional Promedio (ADX). El objetivo es generar señales de compra o venta robustas que no dependan de una única condición de mercado, sino de un consenso entre indicadores que miden la tendencia, el momentum y la fuerza del precio.

Para que se genere una señal de operación, se requiere que al menos dos de los tres indicadores estén de acuerdo. Este requisito proporciona una doble confirmación que busca reducir la probabilidad de señales falsas, especialmente en mercados volátiles o sin una dirección clara.

La selección de estos indicadores se basa en una configuración clásica del análisis técnico que permite analizar diferentes facetas del comportamiento del mercado:

- **Media Móvil Exponencial (EMA):** Se utiliza una EMA como el principal filtro de tendencia. Su función es determinar el estado general del mercado, definiendo si este se encuentra en una fase alcista o bajista.
- **Índice Direccional Promedio (ADX):** Mide la fuerza de la tendencia actual, sin importar su dirección. Su rol es crucial para evitar operar en mercados laterales o de rango, donde las estrategias de seguimiento de tendencia suelen ser ineficaces.
- **Convergencia/Divergencia de Medias Móviles (MACD):** Es un oscilador de momentum que identifica la velocidad y la aceleración del precio. Se utiliza para determinar los puntos de entrada óptimos dentro de una tendencia establecida.

En conjunto, esta combinación de indicadores permite responder a tres preguntas fundamentales antes de cada operación: ¿Cuál es la tendencia principal? (EMA), ¿Es la tendencia lo suficientemente fuerte? (ADX), y ¿Es este un buen momento para entrar? (MACD). La robustez de la estrategia radica en esta complementariedad, donde la confirmación de al menos dos de estas condiciones proporciona una base sólida y confiable para la toma de decisiones en el mercado.

Análisis y preprocesamiento de datos

Para la realización de este proyecto se utilizó un conjunto de datos del par de criptomonedas BTC/USDT, que contiene los precios de apertura, máximo, mínimo y cierre, entre otros, con una frecuencia horaria. El periodo analizado abarca desde el 17 de agosto de 2017 hasta el 22 de septiembre de 2025, comprendiendo un total de aproximadamente 71,000 registros.

El preprocesamiento de los datos si fue necesario para asegurar la calidad del análisis y consistió en lo siguiente. Primero, se estandarizaron los nombres de las columnas a minúsculas para garantizar la consistencia. Posteriormente, se transformó la columna 'date' a un formato datetime estándar; cualquier registro cuya fecha presentara un formato incorrecto fue convertido a un valor nulo (NaT) y subsecuentemente eliminado del conjunto de datos para no introducir errores en el análisis. Una vez limpia, la columna 'date' se estableció como el índice del DataFrame. Adicionalmente, se realizó una búsqueda y eliminación de fechas duplicadas para evitar sesgos en los cálculos de los indicadores y en los resultados del backtesting. Finalmente, el conjunto de datos fue ordenado cronológicamente y se seleccionó el subconjunto final de columnas requeridas para el análisis técnico: open, high, low, close y volume.

Metodología e Implementación

La metodología de este proyecto se diseñó con el objetivo de desarrollar y validar rigurosamente una estrategia de trading usando análisis técnico. Buscando un desempeño bueno durante todos los periodos de tiempo al mismo tiempo que tratando de evitar el sobre ajuste. El proceso se dividió en tres partes: diseño de la estrategia, simulación en un entorno de backtesting realista y un proceso de optimización y validación.

Diseño de la estrategia

La estrategia que ya fue definida y explicada anteriormente se basa en un sistema de confirmación de señales que utiliza tres indicadores técnicos complementarios para tomar decisiones de entrada al mercado. Para generar una señal de comprar o venta, se requiere que al menos dos de los tres indicadores estén de acuerdo.

Entorno de Backtesting

Para evaluar el desempeño histórico de la estrategia, se desarrolló un entorno de backtesting, el cual sirve para simular eventos en condiciones realistas, en este caso quisimos crear las condiciones de un mercado realista, y para eso se implementaron:

Ejecución de Posiciones: El sistema puede ejecutar tanto posiciones largas como cortas, dejando que la estrategia pueda capitalizar en mercados alcistas como bajistas.

Costos de transacción: De esta manera reflejamos los gastos operativos, ya que todas las operaciones tienen un costo y en este caso la comisión fue del 0.125%

Gestión de Capital: Se buscó implementar un modelo de dimensionamiento de posición de fracción, en otras palabras, en lugar de invertir una cantidad fija de dinero o del activo, cada operación utiliza un porcentaje del capital total disponible en la cuenta. Esto nos permite que el tamaño de la posición crezca si nos va bien pero que se reduzca cuando nos va mal.

Gestión del Riesgo: Se agregaron Stop Loss y Take Profit como hiperparámetros los cuales más adelante se optimizan, con ellos limitamos las pérdidas y aseguramos una ganancia.

Proceso del trabajo del Backtesting para cada vela en los datos

1. **Inicialización:** Se definen el capital inicial, la posición (en cero) y el precio de entrada.
2. **Bucle Principal:** Se itera a través de cada registro (vela horaria) del conjunto de datos.
3. **Verificación de Cierre:** Dentro del bucle, la primera acción es comprobar si existe una posición abierta. Si es así, se evalúa si el precio actual activa el **Stop Loss** o el **Take Profit**. Si lo hace, la posición se cierra y el capital se actualiza.
4. **Verificación de Apertura:** Si no hay ninguna posición abierta, se comprueba si las condiciones de los indicadores generan una **señal de compra o venta**. Si hay señal y capital suficiente, se abre una nueva posición, se actualiza el capital y se registra el precio de entrada.
5. **Cálculo de Valor:** Al final de cada iteración, se calcula y almacena el valor total del portafolio (efectivo + valor de la posición si existe).
6. **Resultado Final:** Al terminar el bucle, se devuelve la serie de tiempo con la evolución del portafolio.

Es importante destacar que el **mismo motor de backtesting**, con idénticas reglas de simulación (cálculo de comisiones, gestión de capital, lógica de ejecución), se utilizó de manera durante las tres fases (train, test y validation). De esta forma, una vez optimizados los parámetros en el conjunto de entrenamiento, estos se introducen en el backtesting para medir su verdadero rendimiento en los datos de validación y prueba, garantizando que los datos fueron puestos a prueba y que realmente son buenos.

Optimización de Hiperparámetros

Para evitar el sobre ajuste y al mismo tiempo encontrar la mejor combinación de parámetros, se implementaron estas herramientas:

Calmar Ratio: El objetivo de la optimización fue maximizar el Calmar Ratio. Se eligió esta métrica porque ponderada el retorno anualizado en función de máximo drawdown, enfocándose en la eficiencia de la estrategia para recuperarse de sus peores rachas de pérdidas.

Optimización Bayesiana: Para encontrar los hiperparámetros óptimos se utilizó la librería optuna, la cual realiza la búsqueda de los mejores valores para nuestros hiperparámetros. Como ya se había mencionado anteriormente, el objetivo fue maximizar el Calmar Ratio. Los parámetros optimizados incluyeron los periodos de los indicadores (EMA, MACD, ADX) al igual que los valores de Stop Loss, Take Profit y el tamaño de posición.

Walk-Forward: Este método de validación, el cual se diseñó para series de tiempo, se utilizó para garantizar que los parámetros eran buenos y no solo suerte. El conjunto de datos de entrenamiento, que en nuestro caso fue del 60% del data set, fue dividido en 10 segmentos (chunks). La optimización se corrió de forma iterativa sobre estos, buscando la combinación de parámetros que demostraran un rendimiento consistente a través de diferentes periodos del mercado.

División y uso de los Datos: Se dividió el data set en tres partes independientes, La primera con el objetivo de encontrar la mejor combinación de hiperparámetros optimizados con optuna, y las otras dos se partes se utilizan para confirmar que los hiperparámetros encontrados son buenos y no pura suerte.

- Conjunto de Entrenamiento: fue el 60% de los datos, aquí es cuando se utilizó el optimizador (Walk-Forward y Optuna) para encontrar una combinación de parámetros que funcionaran bien durante todo el data set.
- Conjunto de Validación: fue el 20% de los datos, en esta fase buscamos realizar la primera prueba para ver si los parámetros que encontramos en el data set realmente son buenos y también buscamos comprobar si hay sobreajuste o no.

- Conjunto de Prueba Final: fue el último 20% de los datos, estos datos no se utilizaron en ninguna etapa de desarrollo o validación. Es la última evaluación que le hacemos a los parámetros que se encontraron en el mercado.

Definición del Espacio de Búsqueda de Hiperparámetros:

Para los periodos de los indicadores buscamos que los rangos establecidos cubrieran los valores que se utilizan en la práctica, pero dándoles cierta libertad.

ema_len (Rango: 50-200) Los valores comunes para un filtro de tendencia a largo plazo son 100 o 200. Un valor más bajo (como 50) hace que el filtro sea más sensible y se adapte más rápido a las nuevas tendencias, aunque podría dar más señales falsas. Un valor más alto (como 200) actúa como un filtro muy conservador, confirmando únicamente las tendencias más grandes y establecidas.

macd_fast (Rango: 7-21) y macd_slow (Rango: 22-50)

Los valores estándar son 12 y 26. Este rango nos permite probar MACDs más rápidos (sensibles a cambios de corto plazo) y más lentos (más suaves), sin alejarnos demasiado de la norma. Mantenemos la restricción de que fast siempre sea menor que slow.

macd_signal (Rango: 7-14) El valor estándar es 9. Un valor más bajo (como 5) hace que la línea de señal sea muy reactiva, generando cruces (y por tanto, señales de entrada) más tempranos. Un valor más alto (como 14) suaviza la señal, lo que resulta en menos cruces y señales más tardías, pero potencialmente más fiables.

adx_len (Rango: 10-21)

El estándar es 14. Un valor más bajo (como 10) hará al ADX muy reactivo, detectando tendencias cortas. Un valor más alto (como 21) solo confirmará tendencias muy establecidas y largas.

adx_threshold (Rango: 22-35)

El consenso es que una tendencia es fuerte por encima de 25. Empezamos en 22 para ser un poco más flexibles y llegamos hasta 35 para buscar solo las tendencias más explosivas y claras, filtrando mucho ruido.

stop_loss (Rango: 0.02 - 0.08)

Un Stop Loss debe limitar las pérdidas sin ser "ahogado" por la volatilidad normal. Para un activo volátil como Bitcoin, un stop menor al 2% podría saltar constantemente. Ponerlo por encima del 8% ya representa una pérdida considerable del capital en una sola operación.

take_profit (Rango: 0.04 - 0.15)

Buscamos una buena relación riesgo/beneficio. El rango empieza en el doble del stop loss mínimo (4% vs 2%) y se extiende hasta un 15%, que es una ganancia muy saludable pero aún realista para un solo movimiento tendencial.

n_shares (Rango: 0.1 - 0.5)

Este parámetro define cuánto de tu capital arriesgas en cada operación. Invertir menos del 10% podría dar rendimientos bajos. Invertir el 100% no es recomendable porque no deja margen para slippage o comisiones. Este rango busca un balance agresivo pero prudente.

Proceso del trabajo de la optimización

1. **Llamada de Optuna:** El proceso comienza cuando Optuna llama a la función objetivo para una nueva prueba (trial), sugiriendo un nuevo set de hiperparámetros.
2. **Ejecución de Walk-Forward:** Dentro de la función objetivo, se inicia el proceso Walk-Forward sobre el conjunto de entrenamiento.
3. **Bucle de Segmentos:** Se itera a través de los 10 segmentos (chunks) de los datos de entrenamiento.
4. **Backtesting por Segmento:** En cada iteración, se ejecuta un **backtest completo** (siguiendo el flujo descrito anteriormente) sobre el segmento de datos actual, utilizando los hiperparámetros de la prueba.
5. **Cálculo de Métrica:** Se calcula el **Calmar Ratio** para el resultado de ese backtest.
6. **Agregación de Resultados:** Una vez completado el bucle por todos los segmentos, se promedian los Calmar Ratios obtenidos.
7. **Retorno a Optuna:** El Calmar Ratio promedio se devuelve a Optuna como el resultado de la prueba.
8. **Iteración y Selección:** Optuna repite este proceso para un número definido de pruebas (n_trials), y al final reporta el conjunto de hiperparámetros que obtuvo el mejor Calmar Ratio promedio.

Resultados y Análisis del Desempeño

Para evaluar el desempeño de nuestro algoritmo tanto en la estrategia como en la búsqueda de nuestros hiperparámetros, nos vamos a basar en estas tablas la cuales tienen diferentes cantidades de intentos de la optimización (50, 100 y 150).

50 intentos:

Resumen de Resultados			
	Entrenamiento	Train	Validation
Capital Inicial	1,000,000	1,000,000	1,000,000
Capital Final	1,927,631.27	855,922.32	904, 113.47
Retorno Total	92.76%	-14.41	-9.59%
Retorno Anualizado	14.52%	-9.42%	-5.97%
Máximo Drawdown	-22.82%	-29.1%	-27.41%
Calmar Ratio	0.02	-0.01	-0.01
Sharpe Ratio	0.12	-0.11	-0.06
Win Rate (Días)	50.43 %	50.26%	49.99%
Sortino Rate	0.16	-0.15	-0.08

100 intentos:

Resumen de Resultados			
	Entrenamiento	Train	Validation
Capital Inicial	1,000,000	1,000,000	1,000,000
Capital Final	2,848,409.31	734,629.90	771, 079.52
Retorno Total	184.84%	-26.54	-22.89%
Retorno Anualizado	24.15%	-17.83%	-14.70%
Máximo Drawdown	-44.06%	-38.18%	-42.62%
Calmar Ratio	0.01	-0.01	-0.01
Sharpe Ratio	0.12	-0.12	-0.09
Win Rate (Días)	50.55 %	50.19%	49.53%
Sortino Rate	0.17	-0.16	-0.13

150 intentos:

Resumen de Resultados			
	Entrenamiento	Train	Validation
Capital Inicial	1,000,000	1,000,000	1,000,000
Capital Final	3,663,390.76	1,115,904.76	698, 515.50
Retorno Total	266.34%	11.59	-30.15%
Retorno Anualizado	30.77%	7.23%	-19.70%
Máximo Drawdown	-39.21%	-19.0%	-46.82%
Calmar Ratio	0.02	0.01	-0.01
Sharpe Ratio	0.15	0.07	-0.14
Win Rate (Días)	50.51%	50.36%	49.85%
Sortino Rate	0.21	0.1	-0.19

Descripción de Resultados

Notamos que en general hay un problema con el sobre ajuste en todos los modelos. En los tres casos, el rendimiento pasa de ser positivo en la fase de entrenamiento a ser negativo en la fase de validación. El Ratio de Sharp es un claro indicador de esto, ya que en las tres simulaciones que hicimos empieza siendo positivo y acaba siendo negativo, esto significa que la estrategia no solo deja de ser rentable, sino que no compensa en absoluto el riesgo asumido.

El peor modelo sin duda fue el de 150 intentos, ya que, aunque mostro un rendimiento del 30.77% anualizado en la etapa de train y uno decente en la etapa de test, es el que peor se desempeña de la validación, con un rendimiento de -19.70% anualizado y más aparte con un drawdown de -46.82%

El de 100 intentos queda en segundo lugar, tiene el segundo peor drawdown de -42.62% y su retorno es peor que el de 50 intentos en las tres etapas

El de 50 intentos es el más rescatable de los tres, lo cual no es un alivio teniendo en cuenta que no es rentable. Presenta la perdida anualizada más pequeña de los tres en la validación con un -5.97% al igual que el menor Sharp ratio de -0.06. Pero hasta ahí llegan las buenas noticias, su win rate es del 49.99% lo cual confirma que su capacidad predictiva es prácticamente nula. Pero teniendo en cuenta que fue el mejor de los tres, se presenta su combinación de parámetros obtenidos por nuestra optimización.

Mejor valor objetivo (Calmar Ratio Promedio): 2.8692

Parámetros óptimos encontrados:

- ema_len: 158
- macd_fast: 7
- macd_slow: 42
- macd_signal: 12
- adx_len: 17
- adx_threshold: 27
- stop_loss: 0.07
- take_profit: 0.12
- n_shares: 0.30000000000000004

Gráficos y Tablas de Métricas de Rendimiento

50 intentos

Valor del Portafolio en train (50 intentos)




EOY Returns

Year	Return	Cumulative
2017	-10.38%%	-12.54%
2018	8.85%%	5.83%
2019	14.07%%	12.92%
2020	44.73%%	52.83%
2021	12.8%%	10.03%
2022	10.26%%	9.67%

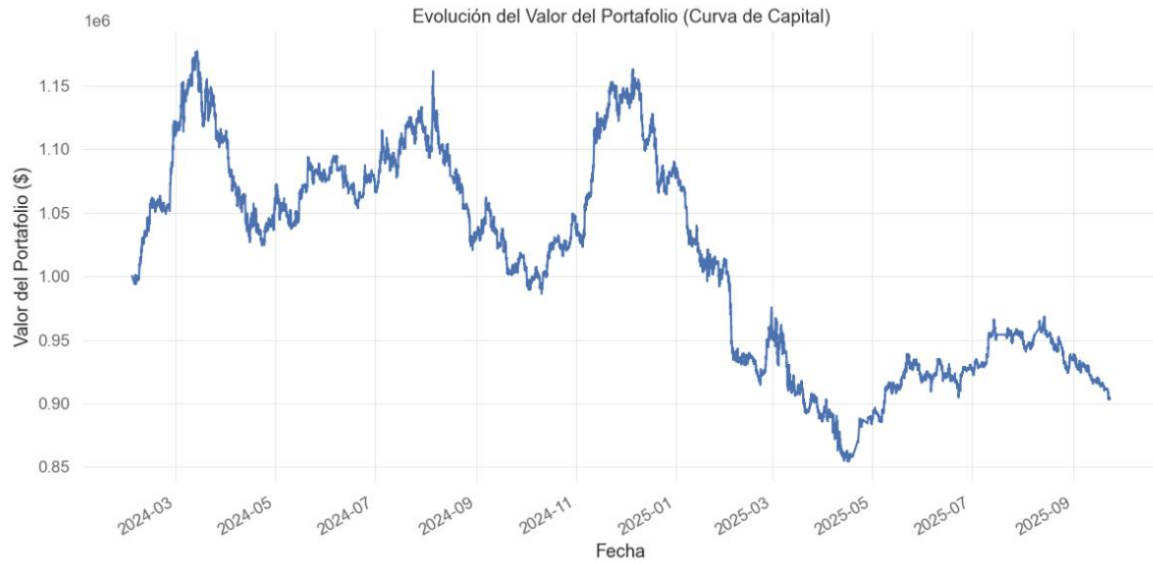
Strategy - Monthly Returns (%)

2017	0.00	0.00	0.00	0.00	0.00	0.00	0.00	3.59	-13.35	5.43	2.76	-10.06
2018	0.76	0.00	3.24	2.30	5.57	3.20	-1.03	2.36	-2.91	-5.81	7.44	-8.28
2019	0.08	-4.14	2.26	7.19	11.26	-2.13	-8.43	3.33	-0.73	2.77	0.74	1.41
2020	-2.49	2.80	14.96	4.13	-1.36	-0.99	6.84	0.96	-2.06	3.05	6.25	12.75
2021	4.78	9.85	1.87	-0.26	-1.16	-0.37	-0.08	-6.07	-6.26	5.67	-2.54	5.43
2022	7.02	-4.71	-7.38	3.01	2.59	9.87	0.00	0.00	0.00	0.00	0.00	0.00
	JAN	FEB	MAR	APR	MAY	JUN	JUL	AUG	SEP	OCT	NOV	DEC

Strategy - Return Quantiles




Valor del Portafolio en Validation (50 intentos)




EOY Returns

Year	Return	Cumulative
2024	9.2%%	8.42%
2025	-17.52%%	-16.61%

Strategy - Monthly Returns (%)



Strategy - Return Quantiles



100 intentos


Valor del Portafolio en train (100 intentos)



EOY Returns

Year	Return	Cumulative
2017	24.51%%	16.55%
2018	6.32%%	-2.96%
2019	14.44%%	9.4%
2020	48.77%%	52.06%
2021	17.76%%	9.1%
2022	35.8%%	38.85%

Strategy - Return Quantiles



Strategy - Monthly Returns (%)


2017	0.00	0.00	0.00	0.00	0.00	0.00	0.00	5.46	-10.08	3.57	18.01	0.56
2018	-12.23	0.00	-5.37	-3.19	4.17	6.70	-0.15	2.32	-5.29	-12.41	12.40	13.96
2019	-3.29	-2.87	-2.18	13.93	11.24	-2.28	4.14	5.94	-8.60	4.18	0.87	-9.27
2020	7.01	0.12	1.66	-2.28	-8.21	-3.98	6.96	1.21	3.07	13.17	12.28	14.34
2021	18.54	29.66	-17.87	9.68	-6.89	-17.12	-1.25	6.53	-7.32	6.94	-5.34	3.46
2022	6.60	6.96	-3.67	-0.09	6.34	18.98	0.00	0.00	0.00	0.00	0.00	0.00
	JAN	FEB	MAR	APR	MAY	JUN	JUL	AUG	SEP	OCT	NOV	DEC

Valor del Portafolio en Validation (100 intentos)



EOY Returns

Year	Return	Cumulative
2024	21.75%%	20.47%
2025	-42.81%%	-35.95%



150 intentos

Valor del Portafolio en train (150 intentos)




EOY Returns

Year	Return	Cumulative
2017	11.66%%	5.14%
2018	5.68%%	-2.45%
2019	8.74%%	3.78%
2020	76.54%%	101.82%
2021	42.45%%	40.89%
2022	21.84%%	21.03%

Strategy - Monthly Returns (%)

2017	0.00	0.00	0.00	0.00	0.00	0.00	0.00	5.54	-23.22	1.78	8.01	18.04
2018	-22.67	0.00	1.75	-0.58	8.53	7.13	6.25	-2.42	-5.25	-9.94	14.92	5.50
2019	-7.46	-6.82	3.78	12.08	14.75	-6.80	-17.64	4.70	1.38	4.72	6.42	-0.70
2020	14.81	5.32	5.18	15.06	-10.98	-1.63	11.43	1.46	-3.49	5.46	14.36	19.68
2021	-1.49	13.27	-4.33	5.92	-1.43	-8.67	12.05	9.94	-5.16	8.63	7.16	1.77
2022	7.95	-1.37	-5.67	0.63	12.38	6.57	0.00	0.00	0.00	0.00	0.00	0.00
	JAN	FEB	MAR	APR	MAY	JUN	JUL	AUG	SEP	OCT	NOV	DEC

Strategy - Return Quantiles



Valor del Portafolio en Validation (150 intentos)

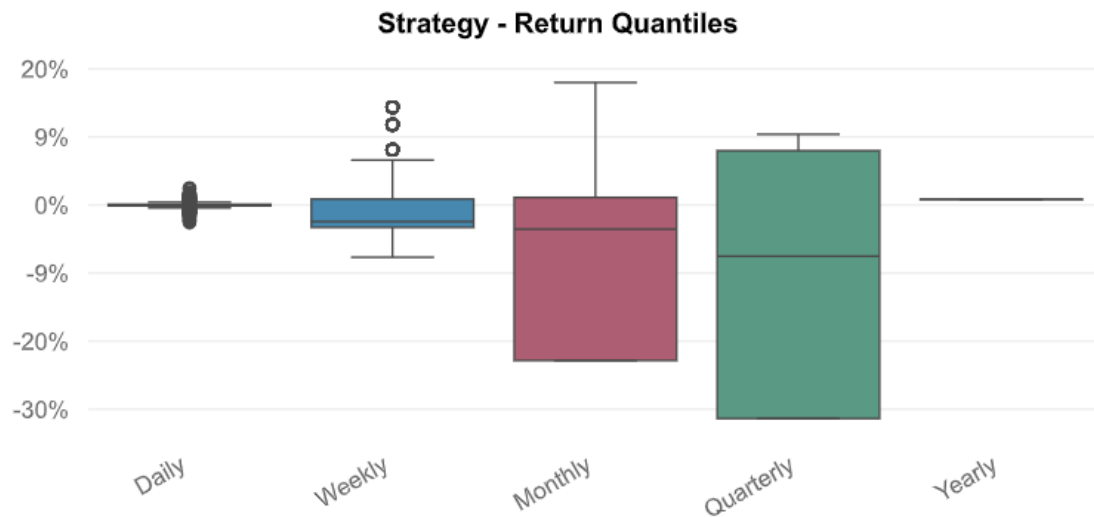


EOY Returns

Year	Return	Cumulative
2024	3.86%%	0.85%
2025	-35.04%%	-30.74%

Strategy - Monthly Returns (%)

2024	0.00	18.01	-6.45	-7.81	-0.79	1.13	0.62	-3.53	-5.78	-2.64	7.20	3.48
2025	-14.05	3.49	-22.83	-0.59	5.63	1.22	3.95	-3.35	-5.51	0.00	0.00	0.00
	JAN	FEB	MAR	APR	MAY	JUN	JUL	AUG	SEP	OCT	NOV	DEC



Análisis de Riesgos y Limitaciones

Gracias a los resultados del proyecto se pueden rescatar 3 riesgos, los cuales son los que más impacto tuvieron en los resultados del proyecto:

- El primer riesgo que debemos tener en cuenta, el cual fue el que más presente estuvo en nuestro modelo, fue el de sobre ajuste. Como logramos notar la estrategia solo mostró un rendimiento positivo en el train, pero durante las siguientes dos etapas, los rendimientos se volvieron negativos. Lo que indica que el modelo no aprendió a generalizar patrones del mercado, si no que buscaba adaptarse perfectamente al movimiento de los datos de entrenamiento.
- El segundo, es el riesgo de drawdown. Aún el “mejor modelo” de 50 intentos exhibió un drawdown de -27.41 en la fase de validación. Una pérdida de esta magnitud ya representa un riesgo considerable si nuestra preocupación es preservar el capital.
- El tercer riesgo viene de la falta de la capacidad predictiva, ya que el win rate de las estrategias en todas las fases se mantuvo consistente en torno al 50%. Lo cual nos indica que la capacidad predictiva del modelo no es mejor que lanzar una moneda al aire. Al tener nula capacidad predictiva somos susceptibles a pérdidas que pueden acabar con nuestro capital de forma rápido debido a las comisiones.

Y nos encontramos con 3 limitantes, activo único, conjunto de indicadores y parámetros estáticos

- La estrategia se desarrollo con un solo activo de fue BTC/USDT. Lo cual por el simple hecho de ser uno hace más difícil la gestión del riesgo, sobre todo el sistemático.
- Al usar solamente tres indicadores es posible que no fuera suficiente para cubrir la complejidad del mercado de criptomonedas. En este caso valdría la pena agregar
- El proyecto tuvo como objetivo encontrar un parámetro de datos que funcionaran bien durante todo el periodo de tiempo del data set. En la vida real se necesitaría un proceso para volver a optimizar de manera periódica para que se logre adaptar a las nuevas condiciones del mercado que vayan surgiendo.

Conclusión

El proyecto tuvo como objetivo desarrollar y validar una estrategia de trading para el par BTC/USDT. Para ello, se implementó una metodología que combinó una lógica de entrada basada en la confluencia de tres indicadores técnicos (EMA, MACD, ADX) con un marco de optimización y validación, incluyendo la optimización bayesiana, el análisis Walk-Forward y una división de datos en conjuntos de entrenamiento, validación y prueba.

El hallazgo principal es que la estrategia, en su forma actual, no es viable ni rentable. A pesar de los intentos de optimización, el modelo demostró no ser capaz de generalizar su rendimiento a datos no vistos, un indicador claro de sobreajuste. Todas las configuraciones probadas mostraron una caída de rendimiento entre la fase de entrenamiento y la de validación, con retornos negativos y una tasa de acierto cercana al 50%, lo que indica una ausencia de capacidad predictiva sobre el mercado.

Aunque el resultado de la estrategia fue negativo, el proyecto fue exitoso en la construcción de un entorno de backtesting y optimización, el cual permitió llegar a esta conclusión de manera fundamentada. Entonces, aunque la estrategia implementada no sirviera en ninguno de los casos, el aprendizaje práctico que se esperaba conseguir con este proyecto se logró.

Bibliografía

- Santander, B. (n.d.). *Indicador MACD*. Banco Santander.
<https://www.bancosantander.es/glosario/indicador-macd-o-moving-average-convergence-divergence>
- Chen, J. (2025, September 9). Exponential Moving Average (EMA): definition, formula, and usage. Investopedia.
<https://www.investopedia.com/terms/e/ema.asp>
- Chen, J. (2025, September 9). Exponential Moving Average (EMA): definition, formula, and usage. Investopedia.
<https://www.investopedia.com/terms/e/ema.asp>
- Noticias legales de Akron. (n.d.).
<https://www.akronlegalnews.com/editorial/37186>
- Archer, C. (2024, April 8). Take profit y stop loss: ¿Qué significa y cómo funciona? IG. <https://www.ig.com/es/estrategias-de-trading/take-profit-y-stop-loss---que-significa-y-como-funciona--240229>